

Reconnaissance d'expressions faciales


CNN, Transfer Learning et détection de visages avec YOLO




Colère



Dégoût




Peur




Joie



Neutre



Tristesse




Surprise

1

Un dataset de visages très déséquilibré

Images par expression (dossier train)



35 887


visages en niveaux de gris, 48×48 pixels, 7 expressions

16,5 : 1

Joie contre Dégoût : on suit donc des métriques par classe, pas seulement l'accuracy

- Pixels divisés par 255, labels en one-hot
- Validation : 15 % du train, stratifiée
- Test officiel (7 178 images) mis de côté jusqu'à la fin

2 Le CNN extrait des motifs, puis classe



Filtres 3×3 , padding same

Peu de paramètres, bords conservés ; le pooling réduit la taille de façon contrôlée.

$32 \rightarrow 64 \rightarrow 128$ filtres

Motifs de plus en plus complexes : bords, puis yeux et bouche, puis expressions.



683 527 paramètres

Seulement 92 672 dans les convolutions grâce au partage des poids ; Dropout ajouté en Partie 6.

Réseau dense de référence (Flatten $\rightarrow$ Dense 256 $\rightarrow$ Dense 7) : 38,1 % en validation. CNN : 52,3 %.

3

Un surapprentissage dès la 4^e époque



52,3 %

en validation à l'époque 4, la meilleure :
poids gardés par l'Early Stopping

79 % / 48 %


train / validation à l'époque 12 (78,9 % /
48,2 %) : le réseau apprend par cœur

Adam (lr 0,001) • lots de 64 • entropie croisée • Early Stopping (patience 8)

Pourquoi : 683 000 paramètres pour 24 000 images, aucune régularisation, labels parfois faux.

Réponse testée ensuite : Dropout, augmentation de données...

Le Dropout seul gagne la comparaison




57,1 %

accuracy de validation du CNN + Dropout (E1), notre meilleur modèle

- Une seule modification à la fois, même graine : l'écart vient de la modification.
- Dropout : surapprentissage divisé par 2 (écart 6,3 → 3,2 points).
- La combinaison sous-apprend : trop de régularisation à la fois.
- Leçon : une combinaison doit être comparée aux modifications seules.

Joie et Surprise reconnues, Tristesse sert de refuge



53,0 %

accuracy test, contre 39,1 % pour le dense

72,4 %

bonne réponse parmi les 2 premières

Bien reconnues : Joie (F1 0,75), Surprise (0,68).

Difficiles : Peur (0,31), Dégoût (0,02, peu d'exemples).

Confusions : Neutre, Peur, Colère → Tristesse (24 à 29 %).

Erreurs sûres : souvent des étiquettes fausses dans FER-2013.

Matrice de confusion du CNN de base sur le test (diagonale = rappel)

6 YOLO trouve les visages, le CNN lit l'expression

Image ou vidéo


YOLOv8n-face

Boîtes + NMS

Gris 48 × 48, /255

CNN

Expression + score




Photos (28) : détection fiable, jusqu'à 25 visages par image, profils compris ; ici Joie de 0,89 à 0,98.

Erreurs typiques : bouche grande ouverte prise pour de la Colère plutôt que de la Surprise ; dégoût pris pour de la Colère.


Vidéo (54 s, tête 3D) : suivi stable ; Joie nette (1,00 à 26 s), le reste hésite entre Neutre et Colère.

Lissage dans le temps : 197 → 65 changements d'expression affichés ; 7,6 images/s, pas encore du temps réel.


Classifieur : MobileNetV2 · YOLO COCO détecte des personnes, d'où un YOLO entraîné sur des visages (WIDER FACE).




Joie 1,00 · 26 s




Tristesse 0,47 · 27 s




Surprise 0,33 · 30 s



Neutre 0,75 · 38 s



Colère 0,65 · 49 s



Peur 0,30 · 50 s

Bilan

Un système complet : de la photo ou de la vidéo à l'expression de chaque visage

Ce qui marche

- CNN : 53 % au test contre 39 % pour le réseau dense
- Dropout : meilleur modèle, 57,1 % en validation
- YOLO : détection fiable, même en foule

Limites

- Peur et Dégoût mal reconnus
- Expressions retenues ou de profil
- Pas encore en temps réel (7,6 images/s)

Pistes

- Plus de données pour les classes rares
- Utiliser le meilleur modèle (E1) pour les photos et la vidéo
- Fine-tuner sur des visages issus de YOLO