



Reconnaissance d'expressions faciales

CNN, Transfer Learning et détection de visages avec YOLO


53,0 % au test (CNN) · 57,1 % en validation (Dropout) · 200 visages analysés sur 28 photos · 1 348 images de vidéo annotées




Colère



Dégoût




Peur




Joie



Neutre



Tristesse




Surprise

1

Un dataset de visages très déséquilibré

Images par expression (dossier train)



35 887

visages 48 × 48, gris, 7 expressions


16,5 : 1

Joie (7 215) contre Dégoût (436)

Ensemble	Images	Rôle
Train	24 402	apprendre les poids
Validation	4 307	choisir (15 %, stratifiée)
Test	7 178	mesurer, une seule fois

- Pixels divisés par 255, labels en one-hot
- Répondre toujours « Joie » : 25,1 % d'accuracy, c'est le seuil à battre
- Dégoût = 1,5 % des images ; poids de classes préparés : Dégoût × 9,4, Joie × 0,57
- Métrique de choix : F1 macro, qui compte autant chaque expression

2 Le CNN extrait des motifs, puis classe



Filtres 3×3 , padding same

Peu de paramètres, bords conservés ; le pooling réduit la taille de façon contrôlée.

32 → 64 → 128 filtres

Motifs de plus en plus complexes : bords, puis yeux et bouche, puis expressions.


683 527 paramètres

Seulement 92 672 dans les convolutions grâce au partage des poids ; Dropout ajouté en Partie 6.

Modèle (validation)	Paramètres	dont convolutions	Perte val	Accuracy val	Accuracy test	F1 macro test
Toujours « Joie »	0	—	—	25,1 %	24,7 %	0,057
Réseau dense (Flatten → Dense 256 → Dense 7)	591 879	0	1,596	38,1 %	39,1 %	0,300
CNN (3 blocs + Dense 128)	683 527	92 672	1,251	52,3 %	53,0 %	0,447

3

Un surapprentissage dès la 4^e époque



Adam (lr 0,001) • lots de 64 • entropie croisée • Early Stopping (patience 8)

Époque	Moment	Perte train	Perte val	Acc. train	Acc. val	Écart
1	début	1,665	1,514	34,4 %	41,4 %	-6,9 pts
4	meilleure (perte val min.)	1,167	1,251	56,0 %	52,3 %	+3,7 pts
12	arrêt (Early Stopping)	0,585	1,751	78,9 %	48,2 %	+30,7 pts

52,3 %

en validation à l'époque 4, la meilleure : poids gardés par l'Early Stopping

+30,7 pts

d'écart train / validation à l'époque 12 : le réseau apprend par cœur

Pourquoi : 683 527 paramètres pour 24 402 images, aucune régularisation, labels parfois faux.

Après l'époque 4 : perte train ÷ 2 (1,17 → 0,59), perte val +0,50.


Coût : 382 mises à jour par époque, 12 époques en 0,8 min (GPU T4).

Réponse testée ensuite : Dropout, augmentation de données...

4

Le Dropout seul gagne la comparaison

F1 macro en validation (même protocole pour tous)



57,1 %

accuracy val. du CNN + Dropout (E1), notre meilleur modèle


÷ 2

surapprentissage : écart train / val 6,3 → 3,2 pts

Expérience (validation)	Acc. val	F1 macro	Écart	Rappel Dégoût	Époques
E0 CNN de base	53,2 %	0,454	6,3	0,02	5
E1 Dropout 0,25 / 0,5	57,1 %	0,509	3,2	0,15	25
E3 Augmentation	56,5 %	0,503	3,8	0,15	40
E4 Poids de classes	49,5 %	0,461	2,8	0,37	5
E2 BatchNorm	52,5 %	0,443	7,1	0,00	5
Combinaison E1 + E3 + E4	49,5 %	0,426	-9,6	0,62	68

- Une seule modification à la fois, même graine, mêmes paramètres : l'écart (train - val, en pts) vient de la modification.
- Dropout : 25 % des neurones éteints au hasard après chaque bloc, 50 % avant la sortie ; +5,5 pts de F1 macro.
- Combinaison : train 39,9 % < val 49,5 %, elle sous-apprend (trop de régularisation), mais rappel Dégoût 0,62 ; au test : 48,6 %.
- MobileNetV2 (ImageNet, fine-tuné) : 51,6 % en val., 52,4 % au test, 3,3 × plus de paramètres.

Joie et Surprise reconnues, Tristesse sert de refuge



Matrice de confusion du CNN de base sur le test (diagonale = rappel)

53,0 %

accuracy test (dense : 39,1 %)

72,4 %

bonne réponse dans le top 2

0,447

F1 macro test (dense : 0,300)

Expression	Précision	Rappel	F1	Gain rappel / dense
Joie	0,81	0,70	0,75	+1 pt
Surprise	0,68	0,68	0,68	+20 pts
Neutre	0,47	0,52	0,49	+18 pts
Tristesse	0,38	0,53	0,44	+11 pts
Colère	0,41	0,46	0,44	+33 pts
Peur	0,39	0,25	0,31	+13 pts
Dégoût	0,50	0,01	0,02	+1 pt

Refuge : Peur → Tristesse 29 %, Neutre → Tristesse 25 %, Colère → Tristesse 24 % ; Tristesse est prédite 1 710 fois pour 1 247 vraies.

Dégoût : 2 prédictions seulement sur 7 178 images (371 exemples d'entraînement).

Confiance : 0,63 en moyenne quand il a raison, 0,46 quand il a tort ; les erreurs très sûres sont souvent des étiquettes fausses.

6 YOLO trouve les visages, MobileNetV2 lit l'expression

Image ou vidéo


YOLOv8n-face

Boîtes + NMS

Gris 48 × 48, /255

MobileNetV2

Expression + score



Détection : 200 visages sur 28 photos (1 à 25 par image, profils et foules compris), confiance YOLO de 0,51 à 0,87 ; boîte rendue carrée + 10 % de marge.


Expressions lues : Neutre 64, Joie 48, Colère 37, Tristesse 33, Peur 12, Surprise 5, Dégoût 0 ; Joie très sûre (0,89 à 0,98 ici).

Erreurs typiques : bouche grande ouverte lue comme Colère au lieu de Surprise ; dégoût lu comme Colère.


Vidéo webcam (10 s, 25 img/s, 250 images) : 3 visages suivis par ByteTrack ; le visage principal passe de Neutre à Joie puis Surprise (jusqu'à 0,92), les 2 autres restent surtout Tristesse — le même refuge que sur le jeu de test.

Lissage EMA ($\alpha = 0,3$) : 35 → 11 changements d'expression affichés (visage principal) ; 133 ms par image = 7,5 img/s, cohérent avec le premier test vidéo (7,6 img/s).


Classifieur des Parties 8-9 : MobileNetV2 (F1 val 0,440 contre 0,426 pour la combinaison) · YOLO COCO détecte des personnes, d'où un YOLO entraîné sur WIDER FACE.



Neutre 0,92 · 1,0 s



Joie 0,76 · 4,8 s



Surprise 0,82 · 8,5 s

Bilan

Un système complet : de la photo ou de la vidéo à l'expression de chaque visage

Ce qui marche

- CNN : 53,0 % au test contre 39,1 % (dense) et 24,7 % (toujours Joie)
- Dropout : meilleur modèle, 57,1 % en val., F1 macro 0,509 (+5,5 pts)
- Joie (F1 0,75) et Surprise (0,68) bien reconnues
- YOLO : 200 visages détectés sur 28 photos, jusqu'à 25 par image

Limites

- Peur (F1 0,31) et Dégoût (0,02) mal reconnus
- Tristesse sert de refuge (jusqu'à 29 % des Peur)
- Expressions retenues ou de profil
- 7,6 img/s : pas encore du temps réel (25 img/s)

Pistes

- Plus de données pour les classes rares (Dégoût : 1,5 %)
- Mettre le CNN + Dropout (E1) dans la chaîne photo et vidéo
- Combiner les régularisations avec des doses réduites
- Ré-entraîner sur des visages extraits par YOLO